DocMind 质量档案 · 一页摘要

基线 origin/develop @ 653715d2（2026-10-24）· 只含已合并事实 · 全文见 docs/evidence/QUALITY.md

1. 问题：企业 RAG 的失败是静默的

检索坏掉时通常不抛异常：返回 HTTP 200 + 空数组；文档状态仍显示 INDEXED；健康检查仍五项全绿。用户把「检索不到」理解为「知识库里没有」，而不是「索引坏了」（docs/research/008_rag-never-indexed.md:10-12）。

2. 证据（只读审计，原始命令输出）

- Elasticsearch 知识库索引 docs.count = 0；hybrid 两路都走 ES，必然 0 结果（008:41-51）。
- MySQL document_chunks：**39 条 chunk，39 条 embedding_id 为 NULL，0 条向量**（008:53-61）。
- **10 份「INDEXED」是假状态**：来自 benchmark_seed，直接写 MySQL，从未进 ES（008:80-92）。
- 5 个查询全部 HTTP 200 + results: [] + search_time: null，其中一条与库中 chunk 近乎逐字对应仍 0 条（008:24-39）；真实上传全部 FAILED：embedding 429「余额不足」（008:63-76）；旧端到端断言 status < 500 对空结果沉默（008:125-128）。

3. 根因：状态与检索之间没有契约

- **写侧**：_mark_success 无条件把状态置为 INDEXED，不检查 ES（backend/app/services/document_status.py:40-42）。
- **读侧**：向量臂硬过滤 exists: embedding；检索通道硬过滤 organization_id（document_status.py:33-38）。
- **观测/评测**：/health 不看知识库数据（008:122）；没有 golden set，回归没有任何信号（008:150-152）。

4. 修复：三条不变量 + 8 个集成测试 + 零容差 eval gate

三条不变量（状态 = INDEXED ⟹ 文档可被检索），document_status.py:27-124：

#	断言	为什么
1	≥1 条 chunk 落在索引里	一条没落 = 不可检索
2	≥1 条带 embedding	向量臂硬过滤 exists:embedding
3	organization_id 一致	检索硬过滤组织，org 错 = 谁都搜不到

写侧：INDEXED 只在回读通过后写入；FAILED 不覆盖 INDEXED（document_status.py:3-9,127-159）。**8 个集成测试**（真实 ES，RUN_INTEGRATION=1）：backend/tests/integration/test_index_verification.py:142-251，含变异验证（:30-37）与独立索引 fixture（:90-135）。

eval gate：28 条 golden（25 正 + 3 负）、7 项指标、零容差、先删后建、确定性伪嵌入、fail-closed（backend/docs/eval-gate-phase1.md:14,100-149；backend/evals/baselines/ci_baseline.json；.github/workflows/ci-fast.yml:371-415,531-553）。

live 基线（2026-10-09）：ClauseHit@1 **80%**；@3=@5 **84%**（95% CI 65.3–93.6%）；NearMiss@5 **12.5%**；MRR **0.82**；EmptyAcc **100%**；errors **0**（eval-gate-phase1.md:92-96）。改基线 = 显式 PR 行为；红灯直接重盖基线 = 把回归合法化，评审拒收（eval-gate-phase1.md:151-164）。

5. 失败案例：Phase 2 实验「没有单一环能修好 4 条」

4 条「带文档全称的条号直查」被 4 个以上环节叠加淹没：msm 剪枝、BM25 标题洪泛、doc 帽 2/文档、终滤 0.15、MMR 剔除、中文数字分词不匹配（backend/docs/eval-gate-phase2-experiment.md:29-37）。**「没有任何单一或已测两环组合修好全部 4 条」**：Q1 只有「帽放开 + 保持 keyword_only」能修，Q3 只有「hybrid + 帽放开」能修（二者互斥）；Q2/Q4 还叠加数形归一化与术语表截断（:58-60）。五环落地后 **gold 回收 = 0/4**，如实记录、不美化（:90-95）。

6. 人类与 AI 的分工

AI：活体读回（ES/MySQL/HTTP）、单变量探针与反事实矩阵、8 个集成测试与变异验证、生成报告。**人类**：定判据与停止条件；拍板产品行为（doc 帽、msm 口径、MMR 适用性）；承担发布与公开责任。**机制**：不依赖「AI 这次是否诚实」，依赖「结论是否可被独立读回」——错误的 bulk 因果故事被对抗评审 F1 指出并实测更正（document_status.py:15-19,44-51）；NearMiss 摆动被独立评审发现后用固定索引协议消除（eval-gate-phase1.md:107-118）。

7. 同日合并的 9 个 PR

f67ef9f8 / a80ae306 / ee30ae4c / 175006de / 0ff446e9 / 00dbeaa7 / 1d4d4060 / 963aeaa1 / 653715d2：均为 origin/develop 祖先（git merge-base --is-ancestor 全部 yes）；只作为已合并事实，不引用生产运行时效果。

8. 局限

docs/METRICS.md 在基线不存在（test -f → MISSING）；eval 只覆盖检索层；28 条 golden 是小样本；本文未在本地复跑 8 个集成测试（ES 不可达、无后端 venv），不引用通过数；integration job 只在 develop push 或目标为 develop 的 PR 上运行（ci-fast.yml:227-230）。

引用均为仓库内 file:line 或命令输出；不含密钥、文档正文、内部 endpoint。数字源：eval-gate-phase1.md / ci_baseline.json / 008_rag-never-indexed.md 原始命令输出。